

# 마음이음 AI 모델 선정 · 가격 정책 타사 비교 기반 **적정 가격 · 사용량** 산정

(주)퍼스트씨앤디

내부 자료

2026. 10. 1. | 실측 280시행 · 적응형 30턴 대화 | 타사 벤치마크 반영



# 01 한눈에 보는 결론

## 핵심 요약

①  
모델은 확정됐다  
확인 턴만 3.8-flash  
지시 준수 56/56 (100%)  
턴당 9.6원

②  
우리는 '말뚱' 사용량  
Replika 하루 70건  
클로바 케어콜 주 2회  
상한 없으면 원가 무한

③  
권장 가격  
무료 20턴 · 유료 50턴  
월 19,900원  
최악 가정에도 흑자

모델 최적화는 끝났고 남은 변수는 가격 — 업계 무료 상한(50~70건)과 우리 원가(턴당 9.6원)가 가격 하한을 결정한다

## 02 모델 선정 — 지시 준수 준수 측정

### 5모델 280시행

| 모델                     | 지시 준수 · 토큰당 원가                 |
|------------------------|--------------------------------|
| gemini-2.5-flash (기존)  | 52/56 (93%) · \$0.0045         |
| gemini-3.1-flash-lite  | 51/56 (91%) · \$0.0045         |
| gemini-3.5-flash-lite  | 50/56 (89%) · \$0.0059         |
| gemini-3-flash-preview | 52/56 (93%) · \$0.0081         |
| gemini-3.8-flash (채택)  | 56/56 (100%) · \$0.0097        |
| 측정 규모                  | 5모델 × 7영역 × 8회 = 280시행         |
| 판정 방법                  | LLM 심판 3분류 (수행 / 다른질문 / 미수행)   |
| 채택                     | gemini-3.8-flash — 인지 확인 토큰 전용 |

#### 가장 중요한 발견

비용 절감이 인지 선별을 컸다  
확인 토큰 입력 토큰 +45% 지불하고  
인지 평가는 0건 — 로그에 실패 없음

#### 왜 '지시 준수'로 재는가

문장 품질은 싼 모델도 통과한다  
깨지는 건 주입한 지시의 수행이고  
기능 누락이라 일반 지표에 안 잡힌다

전 구간을 올리지 않고 확인 토큰 20%만 3.8-flash로 — 비용 증가를 최소화하면서 선별 기능을 되살렸다

## 03 최종 모델 배치 · 톤당 원가

### 호출 지점별

| 호출 지점               | 모델 · 톤당                       |
|---------------------|-------------------------------|
| 동반자 — 수다 톤 (80%)    | 2.5-flash                     |
| 동반자 — 인지 확인 톤 (20%) | 3.8-flash · 동반자 합<br>\$0.0038 |
| 분석기 1차 (선별 라우팅)     | 2.5-flash                     |
| 분석기 정밀 채점           | 3.8-flash · 분석기 합<br>\$0.0031 |
| <b>톤당 합계</b>        | <b>\$0.0069 ~ 9.6원</b>        |

※ 적응형 30톤 대화 실측 · 환율 1,390원 기준 · 서버 TTS 비용 별도

### 적용한 최적화

- 확인 톤만 상위 모델
- 분석기 3.5→3.8 (정확도 ↑ 단가 ½)
- 도메인별 프로토콜 슬라이싱 -7%
- 암묵 캐시 적용 42% (입력 90% 할인)
- 측정 오류 4건 교정 후 확정

▲ 3.8-flash 도입가는 2026-12-31 종료 — 2027년 톤당 약 14.6원으로 오른다 (연말 전 재검토 필요)

## 04 타사 AI 말벗 · 돌봄 사용량

### 실사용 벤치마크

#### Replika

- 하루 약 70건
- 세션 15분 (일부 2시간)
- 유료 \$19.99 / 월

#### Character.AI

- 세션 17.4분
- 하루 3.2세션
- 유료 \$9.99 / 월

#### 클로바 케어콜

- 주 2회 안부 전화
- 통화당 약 1분 15초
- 지자체 B2G · 5만명
- 응답률 96%

#### 효돌 (돌봄인형)

- 상시 거치형 (횟수 무제한)
- 대화+복약+인지퀴즈
- 118개 지자체 5,800대
- 만족도 80.1%

사용 패턴은 말벗 앱(70건/일), 수익 모델은 돌봄 서비스 — 이 조합이 가격 설계의 핵심 제약이다

# 05 타사 가격 · 무료 상한

## 업계 관행

| 서비스          | 무료 상한 · 유료                |
|--------------|---------------------------|
| Talkie       | 하루 50건                    |
| Chai         | 하루 약 70건 · \$13.99        |
| Character.AI | 무제한 · \$9.99              |
| Replika      | 소형 모델 · \$19.99           |
| 마음이음 (제안)    | 무료 20턴 · 유료 50턴 / 19,900원 |

→ 마음이음 제안은 업계 하단 — 무료 20턴 · 유료 50턴

업계 무료 상한

**하루 50~70건**

Talkie 50 · Chai 70

업계 유료 가격

**\$9.99 ~ \$19.99**

월 14,000~28,000원

우리 실측 중앙값

**하루 15턴**

사람이 쓴 40일 기준 (p75 26턴)

※ 타사는 대화 모델만 돌리지만 우리는 매 턴 인지 분석기가 함께 돈다 — 같은 턴 수라도 원가가 높다. 타사의 '건'은 사용자 메시지 1건으로 우리 '턴'과 같은 단위다. 우리 중앙값은 내부·관계자 계정 40일 기준이며 외부 실사용자 데이터는 아직 없다.

## 06 사용량별 1인 월 원가

턴당 9.6원 기준

하루 70턴  
Replika 실사용 평균

20,160원

하루 50턴  
Talkie 무료 상한

14,400원

하루 20턴  
권장 무료 상한

5,760원

Play 수수료 15%를 뺀 수령액이 이 원가를 넘어야 한다 — 가격의 하한선을 결정하는 수치

# 07 가격안 — 두 가지 시나리오

## 월 단위 수지

■ 최대 원가 — 동반자

■ 최대 원가 — 분석가

### 안 A · 보급형 (월 9,900원 / 하루 30턴)

→ 진입 쉬움, 최악 가정에선 -225원 (≈ 손익분기)

수령액  
9,900원 - 수수료 15%

8,415원

최대 원가  
하루 30턴 × 30일

4,750

3,890

8,640원

### 안 B · 표준형 (월 19,900원 / 하루 50턴)

→ Replika 동급 가격 · 최악 가정에도 +2,515원 흑자

수령액  
19,900원 - 수수료 15%

16,915원

최대 원가  
하루 50턴 × 30일

7,920

6,480

14,400원

※ '최대 원가'는 상한을 매일 끝까지 쓰는 최악 가정. 실측 중앙값(하루 15턴)이면 원가 4,320원이라 두 안 모두 흑자다. 안 A는 사용량이 늘수록 적자로 돌아서고, 안 B는 상한까지 써도 2026년 단가에선 흑자다. ▲ 2027년 단가(턴당 14.6원)에서는 안 B의 최대 원가가 21,900원이 되어 역전된다 — 연말 전 모델 재검토가 이 가격의 전제다.

## 08 결론 · 권장

### 판단

#### 모델

확정 — 확인 톤 3.8-flash · 톤당 9.6원

#### 무료 상한

하루 20톤 (실측 중앙값 15톤의 1.3배)

#### 유료

월 19,900원 · 하루 50톤 — 최악에도 흑자

#### 런칭 전략

보급형(9,900원 · 30톤) 프로모션 → 표준형 전환

① 가격 확정 → ② Play 구독 상품 생성 → ③ 서비스 계정 · RTDN → ④ 라이선스 테스터 실결제 → ⑤ 유료 전환 ON

## 09 원가 추가 절감 — 실측 A/B

측정 완료

①

안 쓰던 캐시가 있었다  
구현은 돼 있었지만  
한 번도 켜 적이 없었다  
입력 적중 18% → 86%

②

토큰 비용 -17%  
동일 6턴 A/B 실측  
턴당 10원 → 8원  
모델·프롬프트 동일 = 품질  
동일

③

단, 조건부다  
저장·생성료를 반영하면  
손익분기 10분당 3.4턴  
서버리스 공유 수정이 선행

품질을 건드리지 않고 원가를 더 낮출 여지가 있다 — 남은 레버 7건(분석기 thinking·2단 라우팅·일 1회 배치 등)은 품질 검증 통과분만 적용