

마음이음 AI 원가 · 수익구조 분석

실측 기반 모델 최적화 · 결제 수수료 · 가격 전략

2026-09-30 · FIRST C&D

핵심 요약

가장 싼 모델이 가장 정확했다

분석기를 3.5-flash → 2.5-flash로
교체 시 정확도 96.3% → 100%,
단가는 1/5

비용의 97%가 '입력 토큰'

8,400토큰 시스템 프롬프트를
매 턴 재전송.
캐싱·호출 축소가 핵심

현 구조로는 구독이 적자

원가 ₩11,800 > 순수익 ₩8,415
최적화 + 사용량 제한 필수

→ 모델 교체·중복 호출 제거만으로 턴당 원가 52% 절감 가능. 이후 구독가 ₩12,900 + 하루 사용량 상한으로 마진 24% 확보.

① 현재 비용 구조 (실측)

앱의 실제 시스템 프롬프트로 10턴 대화를 돌려 토큰 직접 측정

측정 항목	실측값
시스템 프롬프트	약 8,400 토큰 (매 턴 재전송)
대화 입력 / 턴	8,431 → 8,991 토큰
대화 출력 / 턴	44 + thinking 170 토큰
대화 비용 / 턴	\$0.00315
분석기 호출	턴마다 2회 (2.5-flash + 3.5-flash)
분석기 비용 / 턴	약 \$0.0115 ← 대화의 3.6배

입력 : 출력 = 97 : 3

10턴 합계

입력 87,103 토큰

출력 2,165 토큰

→ 출력을 줄여도 의미 없음.

입력(프롬프트.호출 수)을

줄여야 비용이 준다.

음성(Live) 경로는 분당 과금 — 입력 \$0.005/분, 출력 \$0.018/분. 10턴·5분 세션 ≈ 오디오 \$0.055 + 분석기 \$0.09 = 약 \$0.14 (₩200)

② 모델 벤치마크 — 성능 vs 가격

인지 채점 정답 매트릭스 54케이스(27설계×2반복) 실측 · matrix-verify

모델	정확도	입력 \$/1M	출력 \$/1M	상대 단가	평가
gemini-3.5-flash (현재)	96.3%	\$1.50	\$9.00	100%	최고가 · 최저 정확도
gemini-3.8-flash	98.1%	\$0.75	\$3.75	47%	최신 · 중간가
gemini-3.5-flash-lite	98.1%	\$0.30	\$2.50	24%	저가 · 동등 성능
gemini-2.5-flash	100.0%	\$0.30	\$2.50	24%	최저가 · 최고 정확도 ★

결론 : 네 모델의 성능 차이는 54표본에서 1~2케이스로 통계적으로 동등 → 최저가 선택이 합리적

현재 최고가 모델(3.5-flash)이 오히려 정확도가 가장 낮았음. 2.5-flash로 교체 시 성능 유지·향상 + 단가 1/5

③ 최적화 방안과 절감 효과

1. 분석기 모델 교체

3.5-flash → 2.5-flash

단가 1/5
정확도 96.3%→100%

즉시

2. 2단 중복 호출 제거

lite-primary가 동일 입력(5,669토큰)
→ 같은 모델이면 2차 호출 무의미

분석기 호출 50% 감소

즉시

3. 시스템 프롬프트 캐싱

8,400토큰 매 턴 재전송
→ Context Cache 적용

대화 입력비 대폭 감소

중기

①+② 적용만으로 : 턴당 \$0.0147 → \$0.0071 (-52%) · 음성 세션 \$0.14 → \$0.094 (-33%)

④ 최적화 후 사용자당 월 원가

음성 1세션 = 10턴 ≈ 5분 기준 · 환율 ₩1,400/USD

사용 유형	하루 세션	월 세션	월 원가 (USD)	월 원가 (KRW)
라이트	1회	30회	\$2.82	약 ₩3,950
보통 (기준)	2회	60회	\$5.64	약 ₩7,900
헤비	3회	90회	\$8.46	약 ₩11,840

사용량 제한이 반드시 필요한 이유

헤비 사용자 1명의 원가(₩11,840)가 구독가 대부분을 소진 → 상한 없으면 많이 쓰는 사용자가 손익을 무너뜨림

권장 : 하루 2세션(20턴) 상한 → 최대 원가를 ₩7,900으로 고정

⑤ 결제 수수료 비교 (한국)

Play 정책상 앱 내 디지털 구독은 원칙적으로 Play 결제 사용 — 외부 PG 단독 사용은 정책 위반

결제 방식	Google 수수료	PG 수수료	합계	비고
Play 인앱결제 (구독)	15%	-	15%	가장 단순 · 기본 선택
한국 제3자 결제 병행	11%	2~3%	13~14%	심사·정산 복잡
웹 체크아웃(외부)	10%	2~3%	12~13%	한국 2026-12-31 적용 예정

→ 1단계는 Play 인앱결제(15%)로 단순하게 시작하고, 규모가 커지면 제3자·웹 결제로 수수료를 낮추는 전략을 권장

주의 : 토스·아임포트 등 외부 PG를 앱 안에서 단독으로 쓰면 정책 위반으로 앱이 삭제될 수 있음

⑥ 비즈니스 모델 · 가격 제안

결제 주체는 보호자 — 보호자 요약 10회 무료 후 구독 전환

플랜	가격/월	제공	수수료 15% 차감	원가	마진
무료	₩0	대화 하루 1세션 · 보호자 요약 10회	-	₩3,950	-₩3,950
기본 (권장)	₩12,900	대화 하루 2세션 · 요약·알림 무제한	₩10,965	₩7,900	₩3,065 (24%)
가족	₩19,900	어르신 2명 · 의사 연결 포함	₩16,915	₩12,000	₩4,915 (25%)

권장안

기본 ₩12,900 / 월

하루 2세션(20턴) 상한

보호자 요약·위급알림 무제한

손익분기

고정비 제외 시 가입자 1명부터 흑자

단, 무료 사용자 1명당 월 ₩3,950 손실

→ 무료 한도를 좁게 유지해야 함

⑦ 실행 로드맵

1단계	모델 최적화	분석기 2.5-flash 전환 + 2단 중복 호출 제거	원가 -52%
2단계	사용량 제한	하루 세션·턴 수 상한 + 초과 안내	손익 방어
3단계	보호자 요약 과금	10회 무료 → 구독 전환 유도	수익화 시작
4단계	Play 인앱결제 연동	구독 상품 등록 · 영수증 검증	결제 가동
5단계	재빌드 · 재심사	AAB 재빌드 → Play 재심사 → 배포	출시